Matemáticas Computacionales

Sesión 16

Cuantificación del Error (I)

Cualquier otra línea diferente a la calculada por medio de una regresión por mínimos cuadrados dará como resultado una suma mayor de los cuadrados de los residuos. Así, la línea es única y, en términos del criterio elegido, es la "mejor" línea a través de los puntos.

Ahora, defínase S_t como la suma total de los cuadrados de las diferencias entre los datos y la media, o

$$S_t = \sum (y_i - \bar{y})^2$$

La medida de dispersión más común para una muestra es la desviación estándar (s_y) respecto de la media, y se calcula por medio de

$$s_y = \sqrt{\frac{S_t}{n-1}}$$

Cuantificación del Error (II)

Anteriormente se definió la suma de los cuadrados como

$$S_r = \sum_{i=1}^{n} e_i^2 = \sum_{i=1}^{n} (y_i - a_0 - a_1 x_i)^2$$

El error estándar para la línea de regresión se determina como sigue

$$s_{y/x} = \sqrt{\frac{S_r}{n-2}}$$

Si $s_{y/x} < s_y$, se puede afirmar que el modelo de regresión lineal es adecuado.

Cuantificación del Error (III)

La diferencia entre las cantidades $S_t - S_r$, cuantifica la mejora o reducción del error por describir los datos en términos de una línea recta en vez de un valor promedio. Como la magnitud de esta cantidad depende de la escala, la diferencia se normaliza a S_t para obtener

$$r^2 = \frac{S_t - S_r}{S_t}$$

donde r^2 se conoce como el *coeficiente de determinación*.

Cuantificación del Error (IV)

La raíz cuadrada del *coeficiente de determinación,* r, es el *coeficiente de correlación*, el cual suele representarse de forma porcentual.

$$r = \sqrt{\frac{S_t - S_r}{S_t}} * 100\%$$

En un ajuste perfecto, $S_r = 0$ y $r = r^2 = 1$, lo que significa que la línea explica el 100% de la variabilidad de los datos. Si $r = r^2 = 0$, $S_r = S_t$, lo que indica que el ajuste no representa mejora alguna.

Cuantificación del Error (V)

Aunque el coeficiente de correlación ofrece una manera fácil de medir la bondad del ajuste, se deberá tener cuidado de no darle más significado del que ya tiene. El solo hecho de que r sea cercana a 1 no necesariamente significa que el ajuste sea bueno. Por ejemplo, es posible obtener un valor relativamente alto de r cuando la relación entre y y x no es lineal. Además, como mínimo, se debe inspeccionar siempre una gráfica de los datos junto con su curva de regresión.

Ejemplo

Calcular la desviación estándar (s_y), el error estándar de la estimación ($s_{y/x}$), el coeficiente de determinación (r^2) y el coeficiente de correlación (r) para los datos de:

x	y
1	0,5
2	2,5
3	2
4	4
5	3,5
6	6
7	5,5